Plano de Trabalho: El Niño e Big Data em Python

Oct 6, 2026 · @Arthur Gabriel Oliveira de Macedo

Visão geral

O grupo vai cruzar dados meteorológicos do El Niño com indicadores de agricultura, saúde, energia e desastres no Brasil, para mostrar onde o fenômeno causa prejuízo, onde traz benefício e qual a força dessas relações. O resultado será um pipeline de big data em Python, um dashboard interativo e uma conclusão baseada nos dados.

Perguntas de pesquisa (cada uma vira uma página do dashboard):

1. A intensidade do El Niño (índice ONI) muda a chuva e a temperatura de forma diferente em cada região do Brasil?
2. Safras como soja, milho e café variam em anos de El Niño, e a variação é positiva ou negativa conforme a região?
3. Existe defasagem entre o ONI e os casos de dengue (por exemplo, de 2 a 4 meses)?
4. A geração hidrelétrica e o nível dos reservatórios caem em anos de El Niño em alguma região?
5. Desastres naturais (secas e enchentes) são mais frequentes ou mais graves nesses anos?

Hipóteses a testar (são hipóteses, não conclusões; os dados podem refutá-las):

- Negativo: seca e calor no Norte e Nordeste, aumento de dengue, pressão sobre a energia.
- Positivo ou misto: mais chuva no Sul, que ajuda algumas culturas mas pode causar enchentes.

A conclusão final deve responder a cada pergunta com número e gráfico, e dizer quando os dados não bastam para afirmar nada.

Bases de dados

Seis bases cobrem o clima e os quatro tipos de impacto. Todas se cruzam por **mês (ou ano) + UF/região**. As fontes abaixo vêm do meu conhecimento prévio e não foram abertas agora; o membro 1 deve confirmar o link, o formato e a licença de cada uma.

Base	Fonte	O que traz	Granularidade	Papel no trabalho
Índice ONI e dados do Pacífico	NOAA (a base que o grupo já tem)	Anomalia da temperatura do oceano, que classifica El Niño, La Niña e neutro	Mensal, desde 1950	Variável principal
Chuva e temperatura	INMET	Estações meteorológicas no Brasil	Diária ou horária	Efeito climático por região
Produção agrícola	IBGE/SIDRA (PAM) ou CONAB	Área, produção e produtividade de soja, milho, café e trigo	Anual, por UF ou município	Impacto positivo ou negativo na lavoura
Dengue	InfoDengue ou DATASUS (SINAN)	Casos notificados	Semanal, por município	Impacto na saúde
Energia	ONS	Geração hidrelétrica e energia armazenada nos reservatórios	Diária ou mensal, por subsistema	Impacto no setor elétrico
Desastres	EM-DAT	Secas, enchentes, mortos e afetados	Por evento	Impacto humano e econômico

Regra de ouro do cruzamento: antes de juntar tudo, o membro 2 cria uma tabela de referência de UF → região e uma tabela de datas (ano, mês, fase do El Niño). Todas as bases se ligam a elas.

Pipeline e ferramentas

O fluxo tem cinco etapas, e cada uma tem um responsável. Troque as ferramentas pelas que a disciplina ensinou, se forem diferentes.

1. **Ingestão:** scripts em Python (`requests` , download direto ou API) salvam os dados crus em uma pasta `raw/` , sem alterar nada.
2. **Limpeza e padronização:** tratar nulos e duplicatas, padronizar datas, códigos IBGE e nomes de UF, e salvar em `clean/` .

3. **Conversão para Parquet:** gravar os dados limpos em Parquet, particionados por ano. Isso reduz tamanho e acelera a leitura.
4. **Processamento distribuído:** PySpark ou Dask para agregações, junções entre bases e cálculo de correlações. Usar SQL (Spark SQL ou DuckDB) onde for mais simples.
5. **Camada analítica e dashboard:** uma tabela final, já cruzada, alimenta o dashboard em Streamlit ou Plotly Dash.

Benchmark obrigatório: medir o tempo e a memória da mesma operação (por exemplo, a junção de ONI com dengue) em pandas puro, em Parquet com pandas e em PySpark ou Dask. Isso mostra o uso dos métodos da disciplina e rende um gráfico próprio.

Organização do repositório: `raw/`, `clean/`, `parquet/`, `notebooks/`, `src/`, `dashboard/`, `docs/`. Todos trabalham no mesmo repositório Git, com um branch por pessoa.

Divisão das 6 frentes

Cada membro é dono de uma etapa do pipeline e entrega algo que o próximo usa. Escrevam os nomes ao lado de cada título e marquem as tarefas conforme avançam. Os membros 3 e 6 são os ganchos da apresentação.

Membro 1: Coleta de dados

Nome: ___

- [ ] Baixar e organizar as seis bases em `raw/`, com scripts reproduzíveis
- [ ] Confirmar licença, período coberto e formato de cada fonte
- [ ] Escrever o dicionário de dados (colunas, unidades, frequência)
- [ ] Registrar as limitações de cada base (falhas, mudanças de método)

Entrega: pasta `raw/` completa e um documento de fontes. **Depende de:** ninguém, começa primeiro.

Membro 2: Limpeza e integração (ETL)

Nome: ___

- [ ] Tratar nulos, duplicatas e outliers de cada base
- [ ] Padronizar datas, UF, região e códigos IBGE
- [ ] Criar as tabelas de referência (UF → região, calendário com fase do El Niño)
- [ ] Juntar as bases na tabela analítica final

Entrega: pasta `clean/` e a tabela cruzada. **Depende de:** membro 1.

Membro 3: Engenharia de big data (gancho 1)

Nome: ___

- [ ] Montar o repositório e o padrão de pastas
- [ ] Converter para Parquet com particionamento
- [ ] Reescrever as agregações e junções em PySpark ou Dask
- [ ] Rodar o benchmark (pandas × Parquet × PySpark/Dask) e gerar o gráfico
- [ ] Revisar o código dos outros membros

Entrega: pasta `parquet/`, código do pipeline e o benchmark. **Depende de:** membros 1 e 2 (começa com dados de amostra).

Membro 4: Análise estatística

Nome: ___

- [ ] Classificar os anos em El Niño, La Niña e neutro (ONI ≥ 0,5 ou ≤ -0,5 por 5 meses seguidos)
- [ ] Calcular correlações com defasagem (0 a 6 meses) entre ONI e cada impacto
- [ ] Comparar médias entre as três fases, com teste estatístico
- [ ] Separar os resultados por região
- [ ] Listar o que é correlação e o que não permite concluir causa

Entrega: notebook de análise e uma tabela com os principais achados. **Depende de:** membro 2.

Membro 5: Dashboard

Nome: ___

- [ ] Desenhar o layout das páginas (esboço no papel ou no Figma)
- [ ] Programar as visualizações em Plotly e o app em Streamlit ou Dash
- [ ] Criar filtros por ano, região e fase do El Niño
- [ ] Testar com a tabela final e corrigir erros de leitura
- [ ] Publicar o app (Streamlit Cloud) ou gravar um vídeo de demonstração como reserva

Entrega: dashboard funcionando. **Depende de:** membros 2 e 4 (começa com dados parciais).

Membro 6: Conclusões e apresentação (gancho 2)

Nome: ___

- [ ] Transformar as perguntas de pesquisa em uma narrativa única

- [ ] Redigir o relatório e a conclusão com base nos achados do membro 4
- [ ] Montar os slides e o roteiro de falas de todos
- [ ] Organizar dois ensaios completos antes da data
- [ ] Preparar as respostas para perguntas prováveis do professor

Entrega: relatório, slides e roteiro. **Depende de:** todos, mas começa cedo com o esqueleto.

Dashboard

O dashboard tem uma página por pergunta de pesquisa e usa pelo menos sete tipos de gráfico diferentes, como o professor pediu.

Página	Visualização	Tipo de gráfico	O que mostra
Visão geral	Linha do ONI desde 1950 com faixas de El Niño e La Niña	Série temporal	Quando e com que força o fenômeno ocorreu
Clima	Mapa do Brasil com anomalia de chuva por UF	Mapa coroplético	Onde choveu mais ou menos que o normal
Clima	Mês × região com anomalia de temperatura	Heatmap	Padrão sazonal por região
Agricultura	Produtividade média por fase (El Niño, La Niña, neutro)	Barras agrupadas	Quais culturas ganham ou perdem
Saúde	ONI e casos de dengue com defasagem	Linhas em eixo duplo e dispersão	Quanto tempo o fenômeno leva para afetar a dengue
Energia	Energia armazenada nos reservatórios por subsistema	Área ou linhas	Efeito na geração hidrelétrica
Desastres	Eventos por tipo e ano	Barras empilhadas	Secas e enchentes ao longo do tempo
Correlações	Correlação entre ONI e cada impacto	Matriz de calor	Quais relações são fortes e quais são fracas
Engenharia	Tempo e memória de pandas × Parquet × PySpark	Barras	Ganho de desempenho do pipeline

Filtros em todas as páginas: período, região ou UF e fase do El Niño. **Cartões no topo:** anos analisados, registros processados, correlação principal e fase atual do fenômeno.

Apresentação

Dois ganchos conduzem a apresentação (os membros 3 e 6) e os outros quatro entram com falas curtas sobre a própria etapa. Ajustem os tempos à duração que o professor definir.

Ordem	Quem fala	Papel	Conteúdo	Tempo sugerido
1	Membro 3 (gancho 1)	Abertura	O que é o El Niño, perguntas de pesquisa e visão do pipeline	3 a 4 min
2	Membro 1	Fala curta	Bases escolhidas e como foram coletadas	1 a 2 min
3	Membro 2	Fala curta	Limpeza e integração, com um exemplo de problema resolvido	1 a 2 min
4	Membro 3 (gancho 1)	Parte técnica	Parquet, PySpark ou Dask e o benchmark	2 a 3 min
5	Membro 4	Fala curta	Método estatístico e principais achados	2 min
6	Membro 5	Fala curta	Demonstração ao vivo do dashboard (primeira página)	2 min
7	Membro 6 (gancho 2)	Fechamento	Percurso do dashboard por pergunta, conclusões e limitações	4 a 5 min

Regras para o grupo:

- Cada gancho cobre as transições entre as falas curtas, para a apresentação parecer uma história só.
- Todos devem saber explicar o pipeline inteiro, porque o professor pode perguntar a qualquer um.
- Ter um vídeo de reserva do dashboard, caso a demonstração ao vivo falhe.

Cronograma e entrega

O trabalho tem quatro fases em sequência, e as fases 2 e 3 se sobrepõem. **Pergunta em aberto:** qual é a data de entrega? Com ela, dá para transformar cada fase em prazos por semana.

1. **Fase 1, planejamento (membros 1 a 6):** fechar as perguntas de pesquisa, escolher as bases, criar o repositório e definir quem faz o quê.
2. **Fase 2, dados (membros 1, 2 e 3):** coleta, limpeza, Parquet e primeira versão da tabela cruzada.
3. **Fase 3, análise e dashboard (membros 4 e 5):** análises estatísticas e primeiras páginas do dashboard, já com dados parciais.
4. **Fase 4, fechamento (membro 6 e todos):** conclusões, relatório, slides e dois ensaios completos.

Checklist final antes de entregar:

- [ ] Todas as perguntas de pesquisa têm resposta com número e gráfico
- [ ] Dashboard roda do zero em outra máquina (com `requirements.txt`)
- [ ] Código no repositório, comentado e com README
- [ ] Benchmark de desempenho incluído no dashboard e no relatório
- [ ] Fontes e licenças dos dados citadas
- [ ] Limitações e o aviso "correlação não é causa" na conclusão
- [ ] Roteiro de falas ensaiado e vídeo de reserva gravado